

LLM으로 어떤 일을 할 수 있을까?

이번 장에서는 대규모 언어 모델, 즉 LLM이 무엇인지 살펴보고 LLM을 활용해 프로그램을 개발하는 경험이 필요한 이유를 알아봅니다. 그리고 이 책에서 다루는 LLM을 활용한 개발 기술은 어떤 단계로 이루어지는지 살펴보겠습니다.

◆

01-1 챗GPT로 시작된 생성형 AI 시대

01-2 LLM을 왜 공부해야 할까?

◆
◆
◆


01-1 챗GPT로 시작된 생성형 AI 시대

영화 <아이, 로봇! ROBOT>에서는 윌 스미스와 인공지능 로봇이 대화하는 장면이 나옵니다. 윌 스미스는 AI 로봇에게 “넌 인간을 흉내 낸 기계일 뿐이야. 로봇이 작곡을 하나? 그림을 그릴 수 있어?”라고 묻자, 인공지능 로봇은 “당신은요?”라고 되물습니다. 이처럼 사람들은 얼마 전 까지도 ‘컴퓨터는 계산을 빠르고 정확하게 하는 대신 창의적인 작업은 할 수 없다’고 여겼습니다.

최근 머신러닝과 딥러닝 기술이 발전하면서 인공지능 활용 분야가 넓어졌지만, 전에는 주로 사진을 분류하거나 공장 생산 라인에서 불량품을 찾아내는 단순하고 반복되는 일에 사용되었죠. 하지만 2025년 현재 컴퓨터는 생성형 AI 기술을 통해 쉽게 그림을 그리고 작곡을 하고 그림을 그릴 수 있습니다.



채팅(챗GPT)



음악 생성
(스노 AI)



이미지 생성
(미드저니)



동영상 생성
(Veo2)

2023년 챗GPT의 등장은 전 세계인에게 충격을 주었습니다. 불과 몇 년까지만 해도 머신러닝과 딥러닝은 일부 IT 전문가만 사용하는 기술이었고 알파고의 충격도 바둑판 위에서만 의미가 있었습니다. 하지만 챗GPT가 가져온 변화는 인터넷을 사용하는 모든 사람에게 영향을 끼치고 있습니다. 친구와 채팅하듯이 챗GPT와 대화하면서 인공지능을 직접 사용할 수 있게 되었으니까요.

챗GPT 같은 생성형 AI에 기반한 서비스는 LLM이 어떻게 활용될 수 있는지를 보여 주는 좋은 예입니다. 인공지능에 기반한 서비스는 사용자와 자연스럽게 대화하고, 대화의 맥락과 요구 사항을 제대로 파악할 수 있는 방향으로 발전하고 있습니다. 수많은 연구자와 기업에서 언어 모델을 활용한 새로운 서비스를 개발·제공하고 있으며, 앞으로도 이런 변화는 더욱 활발해질 것입니다.

대규모 언어 모델, LLM은 무엇일까?

인공지능과 생성형 AI 그리고 대규모 언어 모델에 대해 알아보시다. **인공지능** Artificial Intelligence, AI은 넓은 개념으로 보면 **사람의 지적 능력을 모사하는 컴퓨터 기술**을 의미합니다. 예를 들어 이미지 속의 글자나 사과, 오렌지 등의 사물을 인식하는 기술이나, 머신러닝과 딥러닝을 기반으로 사용자의 취향 데이터를 분석해 성향을 분류하고 상품을 추천하는 기술들이 인공지능에 해당합니다. 또한 규칙 기반 시스템을 사용해 게임에서 특정 거리 안에 들어온 적을 추적하거나 에너지가 부족할 때 도망가는 등의 동작을 하도록 기계적으로 설정한 것도 저수준의 인공지능으로 볼 수 있습니다.

생성형 AI generative AI는 **새로운 데이터를 생성하는 능력에 초점을 맞춘** 인공지능입니다. 텍스트를 입력하면 그 텍스트를 음성 데이터로 변환하거나 사용자가 입력한 텍스트에 적합한 이미지를 생성하는 인공지능이 생성형 AI에 해당합니다.

대규모 언어 모델 Large Language Model, LLM은 방대한 양의 텍스트 데이터를 학습하여 인간의 언어를 이해하고 생성할 수 있습니다. 예를 들어 챗GPT가 활용하는 GPT Generative Pre-trained Transformer는 대규모 언어 모델의 존재를 일반 대중에게 알린 대표적인 모델입니다. 이 모델은 **학습한 텍스트 데이터의 일부를 지운 후, 그 안에 어떤 말이 들어갈지를 확률적으로 예측하고 실제 답과 비교하는 방식으로 학습**되었습니다. **문장들에서 일부 지우고 예측하여 실제 답과 비교**

정답지

A: Hi. How are you?
B: I'm fine. Thank you, and you?

빈칸 채우기 학습

A: Hi. How are you?	1) <u>Thank you, and you?</u>	81%
B: I'm fine. _____	2) I'm fine.	50%
	3) How much?	10%
	4) Get out!	3%


주어진 텍스트의 빈칸을 채우는 데 최적화된 GPT 학습 방식의 예시

GPT와 같은 대규모 언어 모델은 일반적으로 스스로 생각하거나 인터넷을 검색하여 답변을 생성하지 않습니다. 그 대신 **주어진 질문에 가장 적합한 답변을 예측해 생성하는 방식으로 작동**합니다. GPT가 대부분의 질문에 **적절하게 답할 수 있는 이유는 앞 내용을 바탕으로 그에 이어질 내용이 무엇인지 확률적으로 판단하여 그럴듯한 문장을 만들어 낼 수 있기** 때문입니다.

하지만 이 과정에서 잘 모르는 내용인데도 사실이 아닌 잘못된 정보를 생성하는 **환각 현상(hallucination)**을 일으킬 수 있습니다. 이러한 문제는 GPT만의 특성은 아닙니다. 여러분도 비슷한 경험을 했을 것입니다. 예를 들어 확신이 있어서 어떤 주제에 내기를 했다가 실패한 적이 있거나, 학생 시절 시험에서 모르는 문제가 나왔는데 그럴싸한 답을 써본 경험 말이죠. GPT도 이와 비슷한 문제를 겪고 있습니다.

GPT 모델은 외부와 단절된 상태의 사람을 상상하면 쉽게 이해할 수 있습니다. 학습을 완료한 후 그 시점에 머물러 있기 때문이죠. 즉, GPT는 인터넷 검색이나 시계 확인 등을 할 수 없는 상태입니다. 예를 들어 GPT 모델을 활용한 챗 GPT가 처음 대중에게 공개되었을 때 현재 시간을 묻거나 지난 주 빌보드 차트에서 1위가 누구였는지 물어보면 제대로 답하지 못했습니다. 그 모델이 학습을 마친 시점 이후의 정보는 전혀 알지 못했기 때문입니다.

최근에는 챗GPT에게 최신 정보를 물어보면 인터넷에서 검색하거나 복잡한 계산을 할 때 파이썬 코드를 작성하여 계산하고 답변해 주기도 합니다. 이런 기능은 GPT 자체의 발전 덕분이라기 보다는 챗GPT에 인터넷 검색 기능이나 파이썬 코드 실행 기능을 추가하고 GPT가 이를 실행할 수 있도록 제공한 결과입니다.



어둠 속에 갇혀 있는 사람과 비슷한 챗GPT

이제 GPT와 챗GPT의 차이점을 명확히 설명할 수 있겠죠? GPT는 대규모 언어 모델 그 자체이고 챗GPT는 GPT를 기반으로 다양한 분야에서 활용할 수 있도록 필요한 기능을 덧붙여 제공하는 채팅 형태의 서비스입니다. 대규모 언어 모델은 오픈AI의 GPT 이외에도 구글의 제미니, 앤트로픽의 클로드, 메타의 라마 등이 있습니다.

LLM의 종류

지금까지 GPT를 주로 다뤘지만 이 외에도 다양한 회사에서 여러 언어 모델을 출시해 경쟁하고 있습니다. 오픈AI(OpenAI)에서 개발한 GPT는 현재 가장 널리 알려진 언어 모델입니다. GPT는 폭넓은 지식과 유연한 언어 구사 능력을 갖추어서 글쓰기, 번역, 요약뿐만 아니라 코딩에서도 탁월한 실력을 자랑합니다. 최근에는 **텍스트뿐만 아니라 이미지와 비디오, 음성까지 활용할 수 있는 멀티모달 모델(multimodal model)**로 발전하고 있습니다.

제미나이 Gemini는 구글이 개발한 언어 모델로 GPT의 대항마로 자리 잡고 있습니다. 제미나이 역시 텍스트, 이미지, 오디오, 비디오를 모두 처리할 수 있는 모델로 발전하고 있으며 한국어 처리도 수준급입니다.



라마 Llama는 메타에서 발표한 언어 모델로 높은 성능을 자랑하며 오픈소스를 지향합니다. 그래서 이 모델을 구동할 수 있는 컴퓨터 하드웨어를 갖추고 있다면 무료로 사용할 수 있습니다. 물론 고성능 모델은 막대한 컴퓨팅 자원이 필요하므로 일반 PC에서는 실행할 수 없습니다.




라마는 일반 PC에서 실행할 수 있는 소규모 언어 모델도 제공합니다. 이 모델은 로컬 환경에서 실행할 수 있어서 외부로 데이터를 전송할 필요가 없고 비용도 들지 않는다는 장점이 있습니다. 2024년 기준으로 한국어 처리에 아직 부족한 점이 있지만 로컬 환경에서 사용할 수 있다는 장점 때문에 기대를 받고 있는 모델입니다.

클로드 Claude는 오픈AI에서 뜻을 달리하고 나온 직원들이 설립한 앤트로픽 Anthropic에서 개발한 모델입니다. 이 모델은 성능과 크기에 따라 하이쿠 Haiku, 소네트 Sonnet, 오퍼스 Opus 등을 제공합니다.



◆ 클로드에서 제공하는 모델 중 오퍼스가 가장 고급 모델이며 다음으로 소네트, 하이쿠가 있습니다.

딥시크 DeeSeek는 2025년 초, 중국에서 오픈소스로 공개된 언어 모델로 고성능 언어 모델은 마이크로소프트, 구글, 메타 같은 대기업만 개발할 수 있다는 생각을 깨고 전세계에 충격을 주었습니다. 딥시크는 단순히 다음 단어를 예측하는 수준을 넘어 답변을 생성하기 전에 추론 과정을 거쳐 더 나은 답변을 만드는 추론형 모델 딥시크-R1을 공개했습니다. 이로 인해 미국 중심의 언어 모델 시장에 큰 변화를 일으켰고 더 많은 오픈소스 모델이 등장하는 계기를 마련했습니다.



◆ 딥시크-R1 모델은 11장에서 실습합니다.

이 밖에도 여러 종류가 있지만 어떤 언어 모델이든 하나를 충분히 익히면 다른 모델도 그 경험을 바탕으로 빠르게 적응할 수 있습니다. 이 책으로 언어 모델을 활용하는 방법을 익힌다면 다른 모델도 큰 어려움 없이 사용할 수 있을 겁니다.

LLM을 활용한 생성형 AI 서비스의 종류

챗GPT는 대규모 언어 모델을 활용해 어떤 서비스를 만들 수 있는지를 보여주는 대표적인 예시입니다. 챗GPT는 대규모 언어 모델인 GPT를 기반으로 이미지를 생성하는 달리^{Dall-E}, 영상을 생성하는 소라^{sora} 등 다양한 생성형 AI 모델뿐만 아니라 인터넷 검색, 간단한 파이썬 코드 생성 및 실행 등의 기능까지 결합하여 어떤 서비스를 제공할 수 있는지 보여 줍니다. 이 외에도 생성형 AI에 기반한 서비스는 다양하게 출시되어 있습니다.



챗GPT 로고

최근 인기를 끌고 있는 퍼플렉시티^{perplexity}는 인공지능을 기반으로 하는 검색 엔진입니다. 전에는 구글이나 네이버에서 키워드로 검색했지만 퍼플렉시티는 사용자의 질문을 이해하고 관련성 높은 답변을 정리하여 제시하며 출처도 함께 보여 줍니다. Bing^{Bing}에서도 비슷한 방식으로 검색 서비스를 제공하는데, 이런 방식이 인기를 끌자 챗GPT도 검색 버튼을 추가했습니다.




퍼플렉시티 로고



빙 로고

문서 요약이나 회의록 작성 같은 서비스는 이제 셀 수 없이 많은 회사에서 제공하고 있습니다. 국내 통신사인 SKT의 에이닷은 통화 내용을 텍스트로 정리하고 요약하는 서비스를 제공합니다. 또한 온라인 미팅을 할 때 회의록을 자동으로 작성한 뒤 요약해서 참석자에게 이메일로 송부하는 서비스도 등장했습니다. 온라인 미팅의 대표 주자인 줌^{Zoom}은 ‘AI Companion’이라는 이름으로, 삼성SDS는 ‘Knox 미팅’에서 이 기능을 제공합니다.



SKT 에이닷 로고

IT 강의 서비스 플랫폼인 인프런은 강의 질문에 답변해 주는 ‘인프런 AI 인턴’ 서비스를 도입했습니다. 사용자가 동영상 강의를 시청하다가 궁금한 점이 생겨 게시판에 질문을 남기면 인프런 AI 인턴이 내용을 빠르게 파악하고 기존 질문을 검색한 후 적절한 답변을 생성해 줍니다. 저도 인프런에서 동영상 강의를 제공하는데 AI 인턴이 저보다 더 빠르고 정확한 정보로 답변을 제공해서 깜짝깜짝 놀라곤 합니다.



대규모 언어 모델을 활용해 AI 인턴이 답변 서비스를 제공한 모습

이처럼 LLM을 활용한 서비스는 앞으로 계속 쏟아져 나올 것입니다. 만약 이런 서비스들이 어떤 방식으로 동작하는지 이해하지 못한다면 그저 마법처럼 느껴지거나 지나치게 크게 기대했다가 실망할 수 있습니다. 따라서 이와 유사한 서비스를 직접 개발해 보면서 원리를 이해한다면 기존 서비스도 더 효과적으로 사용할 수 있을 것입니다.

01-2 LLM을 왜 공부해야 할까?

지금은 그야말로 GPT로 대표되는 언어 모델과 생성형 AI 시대입니다. 인터넷에서 조금만 검색해도 오픈AI API, 랭체인, 랭그래프, RAG 등 여러 기술의 최신 정보가 쏟아집니다. 인터넷에도 관련된 문서들이 많이 있지만 대규모 언어 모델을 처음 접하는 사람은 어떤 기술부터 익혀야 할지 몰라 배우는 데 시간이 오래 걸릴 수 있습니다. 이 절에서는 이 책에서 배우게 될 기술과 학습 목표를 살펴보겠습니다.

코딩 < 요건 중심 요건에 맞게 코딩 되는지 제어, 점검해야.
테스트 중심 코딩된 테스트 결과만 보겠다.

LLM 프로그래밍 경험이 필요한 이유

이미 시중에 회의록 작성이나 문서 요약 같은 기능을 제공하는 수많은 생성형 AI 서비스가 있는데, 대규모 언어 모델을 활용한 프로그래밍을 왜 경험해야 하는지 의아한 분도 있을 것 같습니다. 하지만 실제 업무는 기업이나 개인의 특수한 요구에 맞춰 추가 작업이 필요한 경우가 많습니다. 예를 들어 회의록을 만들 때 단순히 회의 내용을 요약하는 것을 넘어 기존 이메일에 있던 자료를 함께 검토하고 누락된 내용이 있는지 확인해야 할 수도 있고, 관련 정보가 기밀이라 생성형 AI 서비스에 자료를 업로드할 수 없는 경우도 있습니다.

이런 상황이라면 대규모 언어 모델에 기반한 챗봇이나 AI 에이전트를 직접 개발하거나 외주 개발사를 통해 만들어야 합니다. 하지만 외주 개발을 맡긴다고 해도 개발 과정이나 기술에 관한 이해가 부족하다면 요구 사항을 적절히 제시하기 어렵습니다. 만약 기존 서비스를 이용하더라도 어떤 방식으로 동작하는지 이해한다면 서비스의 강점과 약점을 잘 파악할 수 있으므로 과도하게 기대하거나 과소평가를 하지 않고 서비스를 효과적으로 사용할 수 있습니다.

이 책의 목표는 대규모 언어 모델을 활용해 업무를 자동화하거나 챗봇을 만드는 과정을 직접 경험하면서 생성형 AI와 언어 모델의 장점과 한계를 이해하는 것입니다. 그리고 이러한 한계를 극복하기 위한 기술을 알아보고 어떻게 조합할 수 있는지 체계적으로 파악합니다. 따라서 단순히 여러 기술을 소개하는 데 그치지 않고 실전 문제를 해결하면서 기술을 체득할 수 있도록 구성했습니다. 매 단계마다 여러 기술을 조합해 목적에 맞는 프로그램을 완성해 나가며 단순히 이론적으로 개별 기술을 배울 때는 경험할 수 없는 문제들을 다룹니다. 발생한 여러 문제를 어떻게 보완하고 해결할 수 있는지 배우고 나면 이후에 프로그램을 만들 때 겪을 수 있는 다양한 상황에서도 효과적으로 대처할 수 있을 것입니다.

어떤 언어 모델을 선택해야 할까?

현재 우리가 일상에서 사용하는 노트북이나 PC 환경에서 대규모 언어 모델을 만드는 것은 불가능에 가깝습니다. 웬만한 대기업조차 수집하기 어려운 양질의 텍스트 데이터가 필요하고 이를 학습시키려면 개인이 감당하기 어려운 수준의 컴퓨터 자원도 필요하기 때문입니다. 또한 학습을 완료한 GPT 같은 대규모 언어 모델을 구동할 때에도 대규모 컴퓨터 자원이 필요하므로 일반 PC 혹은 워크스테이션에서 독자적으로 실행하는 것은 거의 불가능에 가깝습니다. 따라서 GPT와 같은 대규모 언어 모델을 발표한 기업들은 모델 자체를 자사 서버에서 구동하고 사용자가 해당 서버에 요청하면 응답해 주는 API 서비스를 제공합니다. 오픈AI와 같은 서비스 제공 업체는 사용한 만큼 비용을 지불하는 방식으로 운영합니다.

이 책에서는 현재 가장 널리 사용하는 GPT 언어 모델을 사용합니다. 언어 모델이 제공하는 다양한 기능을 직접 경험하기 위해 오픈AI의 GPT API를 활용할 예정입니다. API 사용량에 따라 비용을 지불해야 하지만 이 책의 실습에서 사용하는 비용은 몇천 원 수준이므로 그다지 부담스럽지 않을 것입니다.


◆ GPT API는 02장에서 자세히 배웁니다.

한편 대규모 언어 모델을 사용하는 것이 부적합한 경우도 있습니다. 예를 들어 외부로 유출하면 안 되는 회사의 기밀 자료를 GPT와 같은 대규모 언어 모델에서 사용하면 해당 정보가 인터넷을 통해 서비스를 제공하는 서버로 전송되어서 문제가 발생할 수 있습니다. 그리고 API를 지나치게 많이 사용하면 비용이 과도하게 발생할 수 있습니다. 이런 경우에는 로컬에서 사용할 수 있도록 경량화된 소규모 언어 모델(Small Language Model, SLM)을 고려할 수 있습니다.

소규모 언어 모델을 이용하면 사용자의 컴퓨터에서 언어 모델을 구동하여 필요한 기능을 이용할 수 있습니다. 소규모 언어 모델의 성능이 빠른 속도로 발전하고 있지만 GPT와 제미나이 같은 대규모 언어 모델에 비할 바는 아닙니다. 그렇지만 보안이나 비용 등의 이유로 소규모 언어 모델을 사용해야 한다면 이 책의 11장과 16-1절을 참고하기 바랍니다.

LLM의 한계를 보완하는 기술 6가지

대규모 언어 모델은 뛰어난 능력을 갖추었지만 한계도 있습니다. 이를 보완하기 위해 프롬프트 엔지니어링, 파인 튜닝, RAG, 평선 콜링과 도구 호출, 랭체인, 랭그래프 같은 기술을 사용합니다. 대규모 언어 모델의 한계를 보완하고 다양한 작업을 효과적으로 처리할 수 있도록 돕는 기술 6가지를 간단히 살펴보겠습니다. 이 책에서는 파인 튜닝을 제외한 5가지 기술을 실습합니다.





프롬프트 엔지니어링


프롬프트 엔지니어링 **prompt engineering**은 언어 모델의 **답변을 최적화**하기 위해 **입력 프롬프트를 설계**하는 것을 말합니다. **프롬프트**는 언어 모델에게 일종의 **업무 매뉴얼**을 제공하는 **지시문**이라고 생각하면 됩니다. 언어 모델이 아무리 똑똑하다고 해도 제대로 된 답변을 받으려면 **가이드**가 필요합니다. 예를 들어 전화 상담 같은 새로운 업무를 맡길 때 업무 매뉴얼을 제공하는 것과 비슷합니다. 업무의 목적과 대화 방식 등이 업무 매뉴얼에 자세히 적혀 있다면 신입 직원도 더 쉽게 적응할 수 있겠죠.

내가 원하는
답변(좋은 답변)

LLM은 똑똑한
신입사원

◆ 프롬프트 엔지니어링은 이 책의 03장에서 배웁니다.

전문
Data 그냥
넣으면
w뒤틀림
(학습한 거 날아감)



=> 전체 w 변경하면 model 뒤틀리므로
앞 뒤 w만 변경. 파인튜닝

파인 튜닝

일반적으로 대규모 언어 모델은 **광범위한 문서**를 학습하지만 **특정 분야의 전문 지식**이나 **특정 언어**에 취약하기도 합니다. **파인 튜닝** **fine-tuning**은 이미 학습된 언어 모델에 **원하는 분야**나 **특정 용도**에 맞게 **추가 데이터**를 학습시키는 기법입니다. 파인 튜닝은 **전체 모델을 재학습**시키는 것이 아니므로 새로운 모델을 처음부터 만들 때에 비해 **시간과 비용을 적게 들여도 특정 분야에 맞게 최적화**할 수 있다는 장점이 있습니다.

이 책에서는 파인 튜닝을 다루지 않습니다. 대규모 언어 모델 자체가 우리가 흔히 사용하는 PC에서는 구동조차 되지 않으므로 파인 튜닝을 실습하기는 어렵습니다. 그리고 특수한 상황이 아니라면 대부분의 문제는 **프롬프트 엔지니어링**과 **RAG**를 이용해 개선하는 방법이 더 효율적입니다.

RAG

대규모 언어 모델은 학습을 완료한 시점 이후 생성된 외부의 정보는 **알지 못합니다**. 예를 들어 2024년 중반에 발표한 GPT-4o 모델은 모든 정보를 다 학습한 것 같지만 2024년 후반에 발매된 로제와 브루노 마스의 'APT'라는 곡은 전혀 알지 못합니다. 또한 인터넷에 업로드 되지 않고 내 컴퓨터에만 저장된 PDF 문서를 기반으로 답을 해주지도 못합니다.

3가지
기능

RAG **Retrieval Augmented Generation**는 필요한 정보를 검색해서 답변할 때 활용하도록 돕는 기술입니다. 질문이 들어왔을 때 외부 문서나 데이터베이스에서 관련 정보를 찾고 그 내용을 토대로 답변을 생성하게 만듭니다. 즉, 언어 모델이 최신 자료, 기업의 내부 자료, 전문적인 참고자료 등을 바탕으로 답변할 수 있게 해줍니다.

◆ RAG는 9장과 13장에서 자세하게 다룹니다.

평선 콜링과 도구 호출

대규모 언어 모델은 기본적으로 텍스트에 기반하여 다음에 나올 말이 무엇일지 예측하는 방식으로 동작합니다. 따라서 현재 시각이나 위치, 날씨, 주가 같은 내용을 질문하면 답변하지 못합니다. GPT는 컴퓨터이니 복잡한 계산도 정확하게 할 것이라고 기대하지만 실상은 그렇지 않습니다. 대규모 언어 모델 자체는 앞의 문장을 바탕으로 그다음 내용은 무엇일지 추측하는 모델이기 때문입니다. 평선 콜링 `function calling`과 도구 호출 `tool call`은 대규모 언어 모델이 단순 답변에 그치지 않고 외부 API나 직접 만든 함수를 호출하여 그 결과를 바탕으로 답변할 수 있게 하는 기술입니다.

◆ 평선 콜링은 7장, 도구 호출은 8장에서 자세하게 다룹니다.

랭체인

랭체인 `LangChain`은 대규모 언어 모델을 활용하여 애플리케이션을 개발하는 프레임워크입니다. PDF 파일이나 웹 사이트 검색 결과를 언어 모델에 활용하려면 PDF를 전처리하여 텍스트로 변환하거나 웹 사이트의 텍스트를 가져오는 등의 기능을 개발해야 합니다. 랭체인은 대규모 언어 모델과 이런 기능을 결합해서 사용하기 편리하게 해줍니다. 또한 대규모 언어 모델은 문장 생성에만 초점을 맞추므로 특정 양식으로 답변하기 어려울 수 있는데, 랭체인을 이용하면 답변 형식을 강제할 수 있어서 불확실성을 줄여 줍니다. 그뿐만 아니라 GPT로 개발한 애플리케이션을 제미니와 같은 다른 언어 모델로 교체하고 싶을 때 랭체인을 활용하면 대규모 언어 모델의 선언부만 변경하면 바로 적용할 수 있어서 편리합니다.

◆ 랭체인의 사용법은 8~10장에서 자세하게 다룹니다.

랭그래프

대규모 작업을 할 때 여러 사람이 역할을 나눠 협업하는 것처럼, 인공지능도 각기 다른 역할을 부여받은 AI 에이전트들이 협력하여 일을 처리하면 복잡한 작업도 안정적으로 수행할 수 있습니다. 이렇게 여러 AI 에이전트를 만들어 협업하도록 시스템을 구성하는 방식을 멀티 에이전트 `multi-agent`라고 합니다. 멀티에이전트를 구현하는 방법은 여러 가지 있으며 이때 사용하는 프레임워크도 랭그래프 `LangGraph`, 크루 `crewAI` 등 다양합니다. 이 책에서는 랭그래프를 이용하여 대규모 언어 모델에 기반한 여러 AI 에이전트에 임무를 부여하고 서로 협업하는 시스템을 개발합니다.

◆ 랭그래프의 사용법은 12~15장에서 자세하게 다룹니다

★ 한 걸음 더!

평션 콜링과 도구 호출의 차이점이 있나요?

평션 콜링(function calling)과 도구 호출(tool call)은 외부 함수나 API를 활용한다는 점에서 비슷한 역할을 하므로 기술 문서에서 이 두 용어를 혼용하는 것을 볼 수 있습니다. 엄밀히 말하면 평션 콜링은 주어진 함수의 매개변수 형식을 명확하게 정의하고 그 구조에 맞춰 함수를 호출하여 결과를 사용하는 방식입니다. 도구 호출은 랭체인과 같은 대규모 언어 모델 기반 프레임워크에서 텍스트로 요청을 보내 함수를 외부 함수나 도구로 실행시킨 후 그 결과를 처리하는 방식입니다.

아직 랭체인과 GPT API 사용법을 배우지 않아 이 두 개념을 구분하기 어려울 수 있습니다. 대규모 언어 모델만으로는 해결할 수 없는 문제를 외부 도구를 이용해 처리한다는 점에서 두 방식은 같은 기능을 수행한다는 정도만 알고 넘어가도 됩니다. 즉, 지금은 이 두 용어를 동일한 개념으로 생각해도 무방합니다.