


대규모 언어 모델(LLM) 활용과 생성형 AI 기술의 이해



AI의 신대륙을 탐험하다

LLM 생태계 완벽 가이드

1. 서론: 생성형 AI 시대의 도래와 기술적 패러다임의 전환

2023년, '챗GPT 모멘트'가 모든 것을 바꾸다

AI 기술이 전문가의 영역에서 모두를 위한 '협업 파트너'로 전환된 역사적 분기점.

과거 (Before)

AI는 데이터 과학자나 엔지니어의 전유물. 대중에게는 '알파고' 같은 상징적 이벤트나 공장 자동화 등 산업적 용도로만 인식됨.



현재 (After)

생성형 AI의 등장으로 컴퓨터가 창의적 생산의 주체로 부상. '아이폰 모멘트'에 비견될 만큼 AI의 대중적 수용 범위가 폭발적으로 확장됨.

사례:

**Suno AI:**
텍스트로 음악 생성

**Midjourney:**
이미지 생성

**Google Veo:**
텍스트로 비디오 제작

결론: 이러한 도구들은 전문가가 아닌 일반 사용자도 손쉽게 사용하는 일상적 도구가 되었음.

1.1 챗 GPT 모멘트와 인공지능의 민주화

2023 년 챗 GPT(ChatGPT)의 등장은 단순한 기술적 진보를 넘어, 인공지능(Artificial Intelligence, AI)의 대중적 수용 범위를 폭발적으로 확장시킨 역사적 분기점, 이른바 '아이폰 모멘트'에 비견됩니다. 이전까지의 AI 기술, 특히 머신러닝(Machine Learning)과 딥러닝(Deep Learning)은 데이터 과학자나 엔지니어들의 전유물이었으며, 일반 대중에게는 바둑의 '알파고'와 같은 상징적 이벤트나 공장 자동화, 불량품 선별과 같은 산업적 용도로만 인식되었습니다.¹

그러나 생성형 AI(Generative AI)의 시대가 개막하면서 컴퓨터는 인간 고유의 영역이라 여겨졌던 창의적 생산 활동의 주체로 부상했습니다. 영화 <아이, 로봇>에서 묘사된 "로봇이 작곡을 하거나 그림을 그릴 수 있는가?"라는 질문에 대해, 2025 년 현재의 AI 는 명확한 긍정의 답을 제시합니다. 텍스트를 입력하면 음악을 생성하는 '스노 AI(Suno AI)', 이미지를 그려주는 '미드저니(Midjourney)', 그리고 텍스트 프롬프트만으로 고화질 비디오를 제작하는 구글의 'Veo2'와 같은 도구들은 이제 전문가가 아닌 일반 사용자들도 손쉽게 접근할 수 있는 일상적 도구가 되었습니다.¹ 이러한 변화는 인터넷을 사용하는 모든 개인의 업무 방식과 생활 양식에 직접적인 영향을 미치고 있으며, AI 를 도구가 아닌 '협업 파트너'로 인식하게 만들고 있습니다.

1.2 인공지능 기술의 계층적 정의와 LLM의 위치



- **인공지능 (Artificial Intelligence):** 가장 상위의 개념으로, 인간의 지적 능력을 컴퓨터 시스템으로 구현하는 모든 기술을 포괄합니다. 여기에는 규칙 기반(Rule-based) 시스템부터 머신러닝, 딥러닝이 모두 포함됩니다. 예를 들어, 게임 내에서 적 캐릭터가 플레이어를 추적하거나 에너지가 부족할 때 도망가는 단순한 로직 또한 저수준의 AI로 분류됩니다. 또한 쇼핑물의 상품 추천 알고리즘이나 사진 분류 기술 등이 이에 해당합니다.¹
- **생성형 AI (Generative AI):** 데이터의 패턴과 구조를 학습하여, 기존 데이터와 유사하지만 새로운 데이터를 생성해내는 AI의 한 분파입니다. 이는 단순히 입력을 분류(Classification)하거나 예측(Prediction)하는 것을 넘어, 텍스트, 이미지, 오디오, 비디오, 코드 등 새로운 콘텐츠를 창조하는 능력에 초점을 맞춥니다.¹
- **대규모 언어 모델 (LLM, Large Language Model):** 생성형 AI를 구현하는 핵심 기술 중 하나로, 방대한 텍스트 데이터를 학습하여 인간 언어의 문법, 맥락, 의미를 이해하고 생성하는 거대 딥러닝 모델입니다. 트랜스포머(Transformer) 아키텍처를 기반으로 하며, 수천억 개 이상의 파라미터(Parameter)를 보유합니다.

1.3 LLM의 작동 원리: 다음 토큰 예측(Next Token Prediction)과 확률적 생성

LLM의 작동 원리: 확률 기반의 '다음 단어 예측'

LLM은 '사실'을 검색하는 것이 아니라, 문맥상 가장 '그럴듯한(Plausible)' 단어를 확률적으로 이어 붙여 문장을 생성합니다.

입력 문맥 (Context)	예측 후보 단어	확률 (Probability)	선택 (Generation)
Hi. How are	you?	81%	○
	doing?	15%	
	the weather?	3%	

Critical Limitation: 환각 현상 (Hallucination)

원인: 확률적 생성 방식 때문에 모델은 모르는 정보에 대해서도 확신에 찬 어조로 거짓 정보를 생성할 수 있습니다.

Important Distinction: LLM (엔진) vs. ChatGPT (자동차)


기본 모델은 학습 시점(Knowledge Cutoff) 이후의 정보를 모릅니다. 최신 정보 검색이나 코드 실행은 '챗GPT' 같은 서비스가 LLM에 외부 도구를 연동한 애플리케이션 레벨의 기능입니다.

LLM, 특히 GPT(Generative Pre-trained Transformer) 계열 모델의 핵심 작동 원리는 '다음에 올 단어(토큰) 예측'으로 요약할 수 있습니다. 모델은 인터넷상의 방대한 텍스트 데이터를 통해 단어와 단어 사이의 확률적 관계를 학습합니다. 예를 들어 "The sky is"라는 입력이 주어졌을 때, 모델은 학습된 데이터를 바탕으로 "blue"라는 단어가 뒤따를 확률이 가장 높다는 것을 계산해냅니다.

GPT의 학습 방식은 텍스트 데이터의 일부를 지우고(Masking), 그 빈칸에 들어갈 말을 예측한 뒤 정답과 비교하여 오차를 줄여나가는 과정의 반복입니다. 이러한 확률적 생성 방식은 LLM이 문맥에 맞는 자연스럽고 유창한 문장을 구사하게 만드는 원동력이지만, 동시에 **환각 현상(Hallucination)**이라는 치명적인 한계를 내포합니다. 모델은 '사실(Fact)'을 검색하여 답변하는 것이 아니라, 문맥상 가장 '그럴듯한(Plausible)' 단어를 이어 붙이는 방식으로 작동하기 때문입니다. 따라서 모델은 자신이 모르는 정보에 대해서도 확신에 찬 어조로 거짓 정보를 생성할 수 있습니다.

또한, 기본 모델(Base Model)은 학습이 종료된 시점(Knowledge Cutoff) 이후의 사건이나 정보는 알지 못합니다. 챗 GPT와 같은 서비스가 최신 정보를 다룰 수 있는 것은 LLM 자체의 능력이 아니라, LLM에 웹 검색(Browsing) 도구나 코드 실행(Code Execution) 환경을 연동시킨 애플리케이션 레벨의 확장 기능 덕분입니다. 이는 'GPT'라는 엔진과 '챗 GPT'라는 자동차(서비스)를 구분해서 이해해야 하는 이유입니다.

2. 주요 대규모 언어 모델(LLM)의 생태계 및 기술적 특징 상세 분석



2025 년 현재, AI 시장은 빅테크 기업들과 혁신적인 오픈소스 진영이 치열하게 경쟁하며 기술 발전을 가속화하고 있습니다. 각 모델은 고유의 아키텍처와 특화된 기능을 보유하고 있습니다.

2.1 OpenAI 의 GPT 시리즈: 멀티모달의 표준

GPT 시리즈는 현재 가장 널리 알려진 모델로, 압도적인 일반 지식과 추론 능력을 바탕으로 시장의 표준으로 자리 잡았습니다.

- **멀티모달(Multimodal) 진화:** 초기 텍스트 중심의 모델에서 벗어나, GPT-4o(Omni)와 같은 최신 모델은 텍스트, 이미지, 오디오, 비디오를 단일 모델 내에서 동시에 처리하고 이해하는 네이티브 멀티모달 능력을 갖추었습니다. 이를 통해 사용자는 음성으로 대화하면서 동시에 화면의 이미지를 분석해달라고 요청할 수 있습니다.¹
- **생태계:** 챗 GPT 서비스를 넘어, API 를 통해 수많은 스타트업과 기업 애플리케이션의 두뇌 역할을 수행하고 있습니다.

2.2 Google 의 Gemini 및 Veo: 검색과 미디어 생성의 융합

구글은 자사의 검색 엔진 데이터와 인프라를 활용하여 GPT 의 강력한 대항마를 구축했습니다.

- **Gemini:** 텍스트, 코드, 이미지, 영상 처리에 있어 균형 잡힌 성능을 보여주며, 특히 구글

워크스페이스(Docs, Gmail 등)와의 통합이 강력합니다. 한국어 처리 능력 또한 매우 우수하여 국내 사용자들에게도 높은 평가를 받고 있습니다.¹

- **Veo 2 (비디오 생성 모델):** 구글 딥마인드가 개발한 Veo 2 는 텍스트 프롬프트나 이미지를 입력받아 1080p 이상의 고해상도 영상을 생성하는 최첨단 모델입니다.
 - **기술적 특징:** Veo 2 는 '팬(Pan)', '틸트(Tilt)', '돌리(Dolly)'와 같은 영화적 카메라 기법 용어를 이해하고 이를 영상에 반영합니다.³ 또한, 물리학과 피사체의 움직임을 더욱 정확하게 이해하여, 이전 모델보다 훨씬 일관성 있고 현실적인 영상을 만들어냅니다.⁴
 - **활용:** 사용자는 텍스트뿐만 아니라 이미지를 입력하여 해당 이미지가 살아 움직이는 듯한 영상을 만들 수 있으며, 유튜브 쇼츠(Shorts)와 같은 숏폼 콘텐츠 제작에 최적화된 8 초 분량의 영상을 빠르게 생성할 수 있습니다.⁴

2.3 Anthropic 의 Claude: 안전성과 긴 문맥 이해

OpenAI 출신 연구진이 설립한 Anthropic 은 'Helpful, Harmless, Honest(유용하고, 해롭지 않으며, 정직한)' AI 를 목표로 Claude 모델을 개발했습니다.

- **모델 라인업 및 특징:** 성능과 비용 효율성에 따라 세 가지 티어로 구분됩니다.⁵

모델명	특징 및 주요 용도	비고
Claude 3.5 Haiku	가장 빠르고 가벼운 모델. 실시간 챗봇, 단순 데이터 추출, 대량의 문서 처리에 적합합니다.	비용 효율성 최우수
Claude 3.5 Sonnet	속도와 성능의 균형. 특히 **코딩(Coding)**과 복잡한 지시 이행 능력에서 탁월하여 개발자들에게 인기가 높습니다.	범용적 활용도 높음
Claude 3 Opus	가장 강력한 추론 능력. 복잡한 과학적 분석, 창의적 글쓰기, 고도의 논리적 작업에 특화되어 있습니다.	최고 성능

2.4 DeepSeek: 추론형 모델과 오픈소스의 혁신

2025 년 초, 중국의 DeepSeek 가 공개한 **DeepSeek-R1** 은 전 세계 AI 연구자들에게 큰 충격을 주었습니다. 이 모델은 고성능 AI 개발이 막대한 자본을 가진 미국의 빅테크 기업만의 전유물이

아님을 증명했습니다.¹

- **DeepSeek-R1의 핵심 혁신: 추론(Reasoning) 능력 강화:**

- 기존 LLM들이 단순히 다음 단어를 예측하는 데 집중했다면, DeepSeek-R1은 답변을 생성하기 전에 *****생각(Thinking)*****하는 과정을 거칩니다. 이는 OpenAI의 o1 모델과 유사한 방식이지만, 오픈소스로 공개되었다는 점에서 차별화됩니다.⁷
- **순수 강화학습(Pure RL):** DeepSeek-R1-Zero 모델은 인간의 지도 학습(Supervised Fine-Tuning, SFT) 없이, 오직 정답 여부에 따른 보상(Reward)만으로 학습하는 강화학습을 통해 스스로 추론 능력을 발전시켰습니다. 이 과정에서 모델은 스스로 문제를 검증하고, 오류를 수정하며, 전략을 변경하는 '메타 인지' 능력을 보여주었습니다.⁷

- **아키텍처 및 효율성:**

- **전문가 혼합(Mixture of Experts, MoE):** 총 6,710 억(671B) 개의 파라미터를 가지고 있지만, 실제 추론 시에는 370 억(37B) 개의 파라미터만 활성화하는 MoE 구조를 채택했습니다. 이를 통해 거대 모델임에도 불구하고 연산 비용을 획기적으로 절감했습니다.¹⁰
- **증류(Distillation):** DeepSeek는 거대 모델의 추론 능력을 더 작은 모델(Llama, Qwen 기반)에 이식하여, 일반 소비자용 하드웨어에서도 고성능 추론이 가능한 소형 모델들을 공개했습니다.¹⁰

2.5 Meta의 Llama: 로컬 LLM 생태계의 표준

메타(Meta)는 고성능 모델인 Llama 시리즈를 오픈소스로 공개하며 폐쇄적인 AI 생태계에 대항하고 있습니다.

- **온프레미스 및 로컬 구동:** 기업이나 개인이 자신의 서버나 PC에 모델을 다운로드하여 실행할 수 있습니다. 이는 데이터가 외부로 유출되지 않아야 하는 보안 민감도가 높은 환경에서 필수적입니다.¹
- **다양한 파라미터:** 8B, 70B, 405B 등 다양한 크기의 모델을 제공하여 하드웨어 사양에 맞춰 선택할 수 있는 유연성을 제공합니다.

주요 모델 심층 분석: 4대 세력의 기술적 특징 비교

OpenAI (GPT Series)

특징: 압도적 일반 지식과 추론 능력.

기술: 네이티브 멀티모달 (GPT-4o) - 텍스트, 이미지, 오디오, 비디오를 단일 모델에서 동시 처리.

생태계: 챗GPT 서비스를 넘어 API를 통해 수많은 애플리케이션의 두뇌 역할 수행.

Google (Gemini & Veo)

특징: 균형 잡힌 성능, 우수한 한국어 능력, 구글 워크스페이스와 강력한 통합.

기술 (Veo 2): 1080p 이상 고해상도 영상 생성. '팬', '틸트' 등 영화적 카메라 기법 용어 이해 및 반영.

Anthropic (Claude)

철학: 'Helpful, Harmless, Honest'.

라인업:

- **Haiku:** 가장 빠르고 가벼움 (실시간 챗봇, 데이터 추출).

- **Sonnet:** 속도와 성능의 균형 (특히 코딩 능력 탁월).

- **Opus:** 가장 강력한 추론 능력 (과학적 분석, 고도 논리 작업).

DeepSeek & Meta (Open Source)

DeepSeek-R1: 답변 전 '생각(Thinking)'하는 추론 과정 도입. 순수 강화학습 (Pure RL)으로 스스로 추론 능력 발전. MoE 아키텍처로 연산 비용 절감 (671B 파라미터 중 37B만 활성화).

Meta Llama: 로컬 LLM 생태계의 표준. 온프레미스 구동으로 데이터 보안 확보. 다양한 파라미터 크기(8B, 70B 등) 제공.

3. LLM 기반 생성형 AI 서비스 활용 사례 심층 분석

기술이 현실로: 3가지 혁신적인 서비스 활용 사례

1.



정보 검색의 재정의: Perplexity AI

컨셉: 키워드 검색 엔진을 대체하는 '답변 엔진(Answer Engine)'.

핵심 기능: 실시간 웹 크롤링 후 LLM이 정보를 요약 및 종합. 모든 답변에 인용(Citation)을 명시하여 환각 현상 검증. RAG 기술의 가장 성공적인 상용화 사례.

2.



창작의 민주화: Suno AI

컨셉: 텍스트 프롬프트만으로 스튜디오 품질(44.1kHz)의 음악 생성.

핵심 기능: Suno Studio에서 보컬/악기 분리(Stem Separation) 등 전문적 편집 가능. 워너 뮤직 그룹(WMG)과의 파트너십으로 저작권 문제 해결 모색.

3.



업무 효율의 극대화: SKT A. (에이닷)

컨셉: 통화 서비스에 AI를 결합한 개인 비서.

핵심 기능: 통화 녹음의 텍스트 변환 및 핵심 내용 요약.

통화 중 약속을 캘린더에 자동 등록 제안. 음성 인식과 LLM 추론 능력의 결합.

이론적인 모델 기술이 실제 서비스로 구현되어 사용자에게 어떤 가치를 제공하는지 분석합니다.

3.1 정보 검색의 재정의: Perplexity AI (답변 엔진)

Perplexity AI는 기존의 키워드 기반 검색 엔진(구글, 네이버)을 대체하는 '답변 엔진(Answer Engine)'을 지향합니다.¹

● 작동 프로세스:

1. 사용자의 질문 의도를 파악하고, 필요한 경우 질문을 재구성합니다.
2. 실시간으로 웹을 크롤링하여 신뢰할 수 있는 다수의 소스(뉴스, 논문, 블로그 등)를 읽습니다.
3. 수집된 정보를 LLM(GPT-4, Claude 3 등 선택 가능)이 종합하고 요약하여 답변을 생성합니다.
4. **인용(Citation):** 모든 정보에 출처를 각주 형태로 명시하여, LLM의 환각 현상을 검증할 수 있도록 합니다.¹³

- **Pro Search 및 Deep Research:** 단순 검색을 넘어, 복잡한 질문에 대해 AI가 사용자에게 역으로 질문하며 의도를 구체화하거나, 심층적인 다단계 검색을 수행하여 학술 연구나 시장 조사 보고서 수준의 답변을 제공합니다.¹⁵ 이는 RAG(Retrieval-Augmented Generation) 기술의 가장 성공적인 상용화 사례로 꼽힙니다.

3.2 창작의 민주화: Suno AI (음악 생성)

Suno AI 는 "누구나 음악을 만들 수 있게 한다"는 목표 아래 텍스트 프롬프트만으로 고품질의 음악을 생성합니다.


- **기능적 특징:** 사용자가 "비 오는 날 듣기 좋은 재즈 피아노 곡"과 같은 프롬프트를 입력하면, 작사, 작곡, 편곡, 보컬, 연주가 모두 포함된 노래를 생성합니다. 최신 v5 모델은 44.1kHz 의 스튜디오 품질 오디오를 지원합니다.¹⁷
- **Suno Studio:** 단순 생성을 넘어 전문적인 작업을 지원합니다. 생성된 곡에서 보컬, 드럼, 베이스 등을 분리(Stem Separation)하거나, 특정 구간의 가사를 수정하고 악기를 교체하는 등 웹 기반의 DAW(Digital Audio Workstation) 기능을 제공합니다.¹⁸
- **산업적 파급력:** 워너 뮤직 그룹(WMG)과의 파트너십을 통해 저작권 문제를 해결하고 아티스트와의 공생을 모색하는 등, 생성형 AI 가 예술 산업에 미치는 영향을 보여주는 대표적 사례입니다.¹⁹

3.3 업무 효율의 극대화: SKT A. (에이닷) 전화

SKT 의 에이닷은 통신사의 강점인 통화 서비스에 AI 를 결합하여 새로운 가치를 창출했습니다.¹

- **기능:** 통화 녹음 내용을 텍스트로 변환(STT)하고, LLM 이 핵심 내용을 요약해줍니다. 단순히 요약하는 것을 넘어, 통화 중 언급된 일정(약속)을 캘린더에 자동 등록하도록 제안하거나, 상대방과의 지난 통화 요약을 미리 보여주어 비즈니스 미팅을 돕습니다.²⁰
- **기술 융합:** 음성 인식 기술과 언어 모델의 추론/요약 능력이 결합되어, '개인 비서'로서의 AI 가능성을 실증했습니다.

4. LLM 애플리케이션 개발 기술: 6 가지 핵심 필라(Pillars)



이미 시중에 다양한 AI 서비스가 존재함에도 불구하고, 기업이나 개인이 직접 LLM 애플리케이션을 개발해야 하는 이유는 명확합니다. **데이터 보안**, **특화된 워크플로우**, **비용 최적화**, 그리고 **맞춤형 기능 구현** 때문입니다.¹ 이를 위해 본 강의에서는 LLM의 한계를 보완하고 기능을 확장하는 6 가지 핵심 기술을 다룹니다.

기본기 다지기: 프롬프트 엔지니어링과 RAG

1. 프롬프트 엔지니어링 (Prompt Engineering)

개념: LLM으로부터 최적의 결과물을 이끌어내기 위해 입력값을 전략적으로 설계하는 기술.


핵심 기법:

- 페르소나 (Persona) 부여: '당신은 20년 경력의 시니어 개발자입니다.'
- 생각의 사슬 (Chain of Thought): '단계별로 생각해서 답해줘.'
- 퓨샷 러닝 (Few-Shot Learning): 원하는 결과물의 예시 몇 개를 제공.

2. RAG (검색 증강 생성, Retrieval-Augmented Generation)

필요성: LLM은 학습되지 않은 최신 정보나 내부 데이터를 모르며, 환각 현상이 있음.

작동 원리 (Visual Flow):



4.1 프롬프트 엔지니어링 (Prompt Engineering)

- **개념:** LLM 으로부터 최적의 결과물을 이끌어내기 위해 입력값(프롬프트)을 전략적으로 설계하는 기술입니다.
- **핵심 기법:**
 - **페르소나(Persona) 부여:** 모델에게 "당신은 20 년 경력의 시니어 개발자입니다"와 같이 역할을 부여하여 전문적인 답변을 유도합니다.
 - **생각의 사슬(Chain of Thought, CoT):** "단계별로 생각해서 답해줘"라고 지시하여, 모델이 중간 추론 과정을 거치게 함으로써 복잡한 문제의 정답률을 높입니다.
 - **퓨샷 러닝(Few-Shot Learning):** 원하는 답변의 예시를 몇 가지 제공하여 모델이 출력 형식과 톤을 모방하도록 합니다.¹

4.2 RAG (검색 증강 생성, Retrieval-Augmented Generation)

- **필요성:** LLM 은 학습되지 않은 최신 정보나 기업 내부의 비공개 데이터(PDF, 이메일 등)는 알지 못하며, 모르는 내용을 지어내는 환각 현상이 있습니다.
- **작동 원리:**
 1. 사용자의 질문이 들어오면, 관련 정보를 외부 데이터베이스(Vector DB)에서 검색합니다.
 2. 검색된 '증거(Evidence)' 텍스트를 프롬프트에 포함시켜 LLM 에게 전달합니다.

3. LLM은 "제공된 문서를 바탕으로 답변해"라는 지시에 따라 사실에 기반한 답변을 생성합니다.
- **의의:** 이를 통해 모델 재학습 없이도 최신 정보를 반영하고, 환각을 획기적으로 줄일 수 있습니다.

4.3 평션 콜링(Function Calling)과 도구 호출(Tool Calling)

LLM의 능력 확장: 평션 콜링과 도구 호출

LLM은 텍스트 생성기일 뿐, 계산이나 실시간 날씨 조회 등 외부 세계와의 상호작용은 불가능. 이 기술은 LLM을 외부 API나 함수와 연결해주는 '다리' 역할을 합니다.

[Technical Deep Dive] 평션 콜링 vs. 도구 호출 비교

구분	평션 콜링 (Function Calling)	도구 호출 (Tool Calling)
주체	OpenAI API 주도 개념	LangChain 등 프레임워크의 범용적 개념
정의	모델이 함수 사용을 판단, 실행에 필요한 인자(Arguments)를 JSON 형태로 반환.	LLM이 외부 도구(검색, 계산기 등)를 사용하도록 추상화된 인터페이스 .
작동 방식	모델은 실행 '요청'만 하고, 실제 실행은 애플리케이션이 담당.	프레임워크가 모델의 요청을 감지하고 자동으로 도구를 실행(Invoke) 후 결과 주입.
특징	엄밀한 스키마 정의 필요.	평션 콜링을 포함하는 상위 개념으로 발전 중.

결론: 두 기술의 본질적 목표는 'LLM이 스스로 해결 못 하는 문제를 외부 도구를 통해 해결하도록 연결하는 매커니즘'으로 동일.

LLM은 본질적으로 텍스트 생성기이므로 계산을 하거나 실시간 날씨를 조회할 수 없습니다. 이 기술은 LLM을 외부 세계의 API나 함수와 연결해줍니다.

[기술 심화] 평션 콜링(Function Calling) vs 도구 호출(Tool Calling) ¹

두 용어는 혼용되어 사용되기도 하지만, 기술적 구현과 프레임워크 관점에서 미세한 차이가 있습니다.

구분	평션 콜링 (Function Calling)	도구 호출 (Tool Calling)
주체	OpenAI API 가 주도한 개념	LangChain 등 프레임워크 및 범용적 개념
정의	모델이 대화 중 특정 함수를 사용해야 한다고 판단하면, 함수 실행에 필요한 인자(Arguments)를 구조화된 JSON 형태로 반환하는 기능.	LLM 이 외부 도구(검색, 계산기, API 등)를 사용하도록 추상화된 인터페이스. 여러 도구를 동시에 호출하거나 결과를 처리하는 전체 파이프라인을 포함.
작동 방식	1. 사용자 질문 2. 모델: "함수 A 를 인자 X 로 실행해줘" (JSON) 3. 앱: 실제 함수 실행 후 결과 반환 4. 모델: 결과를 바탕으로 최종 답변 생성	프레임워크가 모델의 도구 사용 요청을 감지하고, 자동으로 해당 도구를 실행(Invoke)한 뒤 결과를 다시 모델에 주입하여 처리.
특징	엄밀한 스키마(Schema) 정의 필요. 모델은 실행하지 않고 '요청'만 함.	평션 콜링을 포함하는 상위 개념으로 발전 중. 최근 모델들은 스트리밍 도구 호출 등 고도화됨.

결론: 두 기술 모두 **LLM 이 스스로 해결할 수 없는 문제를 외부 도구를 통해 해결하도록 연결하는 메커니즘**이라는 본질적 목표는 동일합니다.

고급 기술: 파인 튜닝, 랭체인, 그리고 멀티 에이전트



1. 파인 튜닝 (Fine-Tuning)

- **개념:** 특정 도메인 데이터(법률, 의료 등)를 추가 학습시켜 모델의 파라미터를 미세 조정.
- **용도:** 특수한 말투 학습, 고도로 전문화된 지식 주입.
- **주의:** 비용과 데이터가 많이 필요. RAG와 프롬프트로 먼저 해결 시도 권장.



2. 랭체인 (LangChain)

- **개념:** LLM 앱 개발을 위한 오픈소스 프레임워크.
- **역할:** 복잡한 AI 로직을 '레고 블록'처럼 조립'하도록 돕는 모듈 제공 (문서 로더, 벡터 저장소 연결, 프롬프트 템플릿 등).



3. 랭그래프 (LangGraph)와 멀티 에이전트

- **랭그래프:** 랭체인 생태계의 에이전트 및 상태 관리 특화 라이브러리. 순환(Cycle)과 분기가 있는 복잡한 로직 구현 가능.
- **멀티 에이전트 시스템:** 하나의 모델이 모든 일을 하는 대신, '검색 담당', '코딩 담당', '검수 담당' 등 역할을 분담한 여러 AI 에이전트들이 협력하여 문제를 해결하는 시스템. 랭그래프는 이들 간의 작업 흐름을 효율적으로 관리.

4.4 파인 튜닝 (Fine-Tuning)

- **개념:** 사전 학습된(Pre-trained) 모델에 특정 도메인의 데이터(예: 법률 판례, 의료 기록)를 추가로 학습시켜 모델의 파라미터를 미세 조정하는 기술입니다.
- **용도:** 특수한 말투를 학습시키거나, 고도로 전문적인 지식이 필요할 때 사용합니다. 하지만 많은 비용과 데이터가 필요하므로, 최근에는 RAG와 프롬프트 엔지니어링으로 먼저 해결을 시도하는 것이 일반적입니다.¹

4.5 랭체인 (LangChain)

- **개념:** LLM을 활용한 애플리케이션 개발을 돕는 오픈소스 프레임워크입니다.
- **역할:** LLM 입출력 표준화, 다양한 문서 로더(PDF, HTML 등), 벡터 저장소 연결, 프롬프트 템플릿 관리 등을 모듈화하여 제공합니다. 개발자는 랭체인을 통해 복잡한 AI 로직을 레고 블록 조립하듯이 손쉽게 구축할 수 있습니다.¹

4.6 랭그래프 (LangGraph)와 멀티 에이전트 시스템

- **랭그래프:** 랭체인 생태계에서 **에이전트(Agent)**와 **상태(State)** 관리를 위해 특화된 라이브러리입니다.
- **기술적 차별점:** 기존 랭체인이 선형적인 작업 흐름(DAG, Directed Acyclic Graph)에

적합했다면, 랭그래프는 순환(Cycle)과 분기, 루프가 있는 복잡한 로직을 구현할 수 있습니다.²⁵

- **멀티 에이전트(Multi-Agent):** 하나의 거대 모델에게 모든 일을 맡기는 대신, '검색 담당', '코딩 담당', '검수 담당' 등 역할을 분담한 여러 AI 에이전트들이 서로 협력하여 문제를 해결하는 시스템입니다. 랭그래프는 이러한 에이전트 간의 상태 공유와 작업 이관(Handoff)을 효율적으로 처리합니다.²⁷
-

5. 실습을 위한 하드웨어 및 인프라 가이드 (2025 년 기준)

LLM 을 학습하고 실습하는 환경은 크게 API 기반의 클라우드 방식과 로컬 하드웨어 방식으로 나뉩니다.

당신의 여정을 위한 준비: 클라우드 API vs. 로컬 환경



API 기반 실습 (Cloud)

How it Works: OpenAI, Anthropic 등의 API를 활용. 이 강의의 주요 실습 방식.

장점:

- 고가의 GPU 없이 최신 SOTA 모델 즉시 사용 가능.
- 초기 구축 비용 없음.
- 사용한 만큼만 지불 (실습 수준에서는 부담 적음).

적합한 경우:

- 빠른 프로토타이핑, 최신 모델 테스트, 초기 비용 최소화.



로컬 LLM 구동 (On-Premise)

How it Works: 개인 PC나 서버에 모델을 직접 다운로드하여 실행.

장점:

- 데이터가 외부로 유출되지 않아 보안에 유리.
- 대규모 사용 시 장기적으로 비용 절감 가능.
- 인터넷 연결 없이 사용 가능.

적합한 경우:

- 데이터 보안이 최우선, 커스터마이징 및 통제권 확보.

5.1 API 기반 실습 (Cloud)

이 강의의 주요 실습은 OpenAI, Anthropic 등의 API 를 활용합니다.

- **장점:** 고가의 GPU 없이도 최신 SOTA(State-of-the-Art) 모델을 즉시 사용할 수 있습니다. 초기 구축 비용이 없으며, 사용한 만큼만 비용을 지불합니다.
- **비용:** 실습 수준에서는 몇천 원에서 몇만 원 수준으로 부담이 적습니다.¹

5.2 로컬 LLM (sLLM) 구동을 위한 하드웨어 가이드

보안, 비용 절감, 또는 인터넷이 없는 환경을 위해 로컬 PC 에서 LLM 을 구동하고자 할 때 필요한 사양입니다.²⁸ 핵심은 **GPU 의 VRAM 용량**입니다. **시스템 메모리(RAM):** VRAM 이 부족할 때 모델의 일부를 시스템 메모리로 넘겨 처리(CPU Offloading)할 수 있으므로, 최소 32GB 이상, 권장 64GB 이상을 추천합니다.

로컬 LLM 구동을 위한 하드웨어 가이드 (2025년 기준)

로컬 LLM 구동의 성공 여부는 **GPU의 VRAM 용량**에 달려 있습니다.

하드웨어 구성	VRAM 용량	구동 가능 모델 (예시)	비고
High-End (엔트리)	24GB (RTX 3090/4090)	Llama 3 70B(양자화), Mistral Large	로컬 LLM 연구/실습을 위한 최적의 가성비 선택.
Mid-Range	16GB (RTX 4080/4070 Ti Super)	Llama 3 8B, Gemma 7B	7B~13B 모델을 쾌적하게 구동.
Budget	8GB ~ 12GB (RTX 3060/4060)	Phi-3, Gemma 2B (고압축 양자화)	입문용. 큰 모델은 실행이 어렵거나 매우 느림.



Special Highlight: Mac (Apple Silicon)

- **핵심 장점:** 시스템 메모리를 VRAM처럼 공유하는 **통합 메모리(Unified Memory)** 아키텍처.
- **의의:** 64GB~128GB 메모리를 갖춘 M2/M3 Max/Ultra 칩은 고가의 NVIDIA GPU 없이도 70B 이상의 거대 모델을 로드할 수 있는 강력한 대안.

추가 권장 사항: 시스템 메모리(RAM)는 최소 32GB, 권장 64GB 이상.

6. 결론 및 향후 전망

생성형 AI와 LLM 기술은 단순한 채팅 도구를 넘어 소프트웨어 개발과 비즈니스 프로세스의 새로운 기반 기술이 되었습니다. 이제 개발자와 기획자는 코드를 직접 작성하는 것만큼이나, ***어떤 모델에게(Model Selection), 어떤 맥락을 주입하고(RAG/Prompting), 어떤 도구를 쥐어줄 것인가(Tool Calling)***를 설계하는 '**AI 오케스트레이션**' 능력이 중요해졌습니다.

DeepSeek-R1이 보여준 것처럼, 앞으로의 AI는 단순히 지식을 인출하는 것을 넘어 스스로 사고하고 추론하는 '**에이전트(Agent)**' 형태로 진화할 것입니다. 본 강의 문서를 통해 독자들이 이러한 기술적 흐름을 이해하고, 실질적인 AI 애플리케이션을 구축할 수 있는 'AI 엔지니어'로서의 역량을 갖추기를 기대합니다.